RECA
REVISTA ELETRÔNICA DE COMPUTAÇÃO APLICADA

Departamento de Computação
Uni-FACEF

DESENVOLVIMENTO E AVALIAÇÃO DE UM MÓDULO DE APRENDIZADO PROFUNDO PARA SEGMENTAÇÃO DE MASSAS EM REGIÕES DE INTERESSE DE MAMOGRAFIAS

João Pedro Guinati Rigoni
Graduando em Engenharia de Software – Uni-FACEF
24653@unifacef.edu.br

Prof. Me. Geraldo Henrique Neto
Docente do Departamento de Computação – Uni-FACEF
geraldo.henriqueneto@gmail.com

Resumo
O trabalho desenvolveu e avaliou um módulo de aprendizado profundo para segmentar massas em regiões de interesse (ROIs) do CBIS-DDSM. Após pareamento, auditoria e separação dos dados por paciente, as imagens e máscaras foram padronizadas em 512 por 512 pixels. A arquitetura U-Net com encoder EfficientNetB0 foi treinada com 882 ROIs, validada em 190 e testada em 181 ROIs de 99 pacientes. O melhor checkpoint e o limiar de binarização foram definidos somente na validação. No teste, o modelo alcançou Dice médio de 0,9071, IoU de 0,8346, precisão de 0,9027, sensibilidade de 0,9183 e especificidade de 0,9849. A análise qualitativa mostrou boa concordância na maior parte dos casos, com dificuldades em algumas lesões irregulares. O módulo delimita massas previamente localizadas, não detecta lesões na mamografia completa, não classifica benignidade ou malignidade e requer validação externa antes de eventual uso clínico.

Palavras-chave: Mamografia. Segmentação de imagens. Aprendizado profundo. Regiões de interesse. Câncer de mama.

Abstract
This study developed and evaluated a deep learning module for breast mass segmentation in regions of interest (ROIs) from CBIS-DDSM. After pairing, auditing, and splitting the data at patient level, images and masks were standardized to 512 by 512 pixels. A U-Net with an EfficientNetB0 encoder was trained on 882 ROIs, validated on 190, and tested on 181 ROIs from 99 patients. The best checkpoint and binarization threshold were selected exclusively on the validation set. On the test set, the model achieved a mean Dice score of 0.9071, IoU of 0.8346, precision of 0.9027, sensitivity of 0.9183, and specificity of 0.9849. Qualitative analysis showed good agreement in most cases, with difficulties in some irregular lesions. The module delineates previously localized masses. It does not detect lesions in full mammograms, classify benignity or malignancy, or support clinical use without external validation.

Keywords: Mammography. Image segmentation. Deep learning. Regions of interest. Breast cancer.

1. Introdução

O câncer de mama permanece relevante para a saúde pública, e a mamografia ocupa papel central na investigação de alterações mamárias. Métodos de processamento de imagens e aprendizado profundo podem apoiar tarefas específicas, como a segmentação, que delimita uma estrutura em nível de pixel, mas não substitui a interpretação do profissional.

Este trabalho segmenta massas em ROIs geradas a partir das anotações do CBIS-DDSM. O recorte preserva detalhes da lesão ao redimensionar a entrada e permite avaliar a qualidade do contorno produzido por uma U-Net com encoder EfficientNetB0. Como a ROI depende da máscara de referência, o sistema pressupõe que a massa já esteja localizada e não realiza detecção nem classificação diagnóstica.

O câncer de mama é caracterizado pelo crescimento desordenado de células no tecido mamário e pode apresentar diferentes comportamentos clínicos. No Brasil, excluídos os tumores de pele não melanoma, foi o câncer mais incidente entre as mulheres nas estimativas para o triênio de 2023 a 2025. O Instituto Nacional de Câncer estimou 73.610 casos novos por ano, correspondentes a uma taxa ajustada de 41,89 casos a cada 100 mil mulheres (INCA, 2022). Esses números mostram a dimensão do problema e reforçam a importância da organização das ações de atenção à saúde.

Uma massa mamográfica corresponde a uma lesão ocupando espaço, observada em diferentes projeções. Sua aparência pode variar de acordo com formato, margem, densidade, tamanho e sobreposição com o parênquima. Em tecidos mais densos ou em lesões com limites pouco definidos, a separação entre a massa e as estruturas vizinhas torna-se mais difícil. Essa diversidade também representa um desafio para os métodos computacionais, que precisam aprender padrões relevantes sem confundir a lesão com o tecido de fundo.

1.1 Problema de Pesquisa

O problema investigado passou a ser a delimitação automática da massa em uma região previamente localizada. Esse recorte preserva melhor a informação visual da lesão e permite concentrar o treinamento na tarefa de segmentação. Ao mesmo tempo, cria uma condição controlada, pois a localização utilizada para formar a entrada provém da própria referência. O desempenho obtido nesse cenário não pode ser transferido diretamente para um sistema que receba mamografias completas.

Diante desse contexto, a questão de pesquisa buscou compreender como desenvolver e avaliar um módulo de aprendizado profundo capaz de segmentar massas em ROIs mamográficas e produzir máscaras semelhantes às anotações de referência do CBIS-DDSM. Para isso, foram considerados o pareamento entre imagens e máscaras, a separação dos dados por paciente, a seleção dos parâmetros exclusivamente no conjunto de validação e a avaliação quantitativa e visual dos resultados.

1.2 Objetivos

1.2.1 Objetivo Geral

Desenvolver e avaliar um módulo computacional baseado em U-Net com encoder EfficientNetB0 para segmentar massas em ROIs extraídas do

CBIS-DDSM, abrangendo preparação dos dados, treinamento, geração de máscaras e avaliação quantitativa e qualitativa. A localização automática na mamografia completa e a classificação de benignidade ou malignidade permanecem fora do escopo.

1.2.2 Objetivos Específicos

1. Selecionar, organizar e auditar as imagens de casos de massas e suas respectivas máscaras no CBIS-DDSM, garantindo a correspondência e a consistência dos pares utilizados.
2. Construir as regiões de interesse a partir das anotações de referência e preparar as imagens para a entrada de 512 por 512 pixels do modelo.
3. Separar os dados por paciente em conjuntos de treinamento, validação e teste, evitando o compartilhamento de imagens do mesmo indivíduo entre subconjuntos.
4. Implementar e treinar uma arquitetura de segmentação baseada em U-Net com encoder EfficientNetB0.
5. Avaliar as máscaras geradas por meio de métricas de segmentação e análise visual, utilizando a validação para selecionar o melhor checkpoint e o limiar de binarização e preservando o conjunto de teste para a avaliação final.

1.3 Justificativa e Relevância

A relevância decorre da incidência do câncer de mama e do potencial de ferramentas computacionais apoiarem tarefas delimitadas. A segmentação transforma o achado em uma representação espacial por pixels, útil para analisar contornos e estruturar etapas posteriores, desde que suas capacidades e limitações sejam apresentadas com clareza.

O uso de ROIs mantém a massa proporcionalmente maior na entrada de 512 por 512 pixels, mas transfere a localização para a anotação de referência. O CBIS-DDSM favorece reprodução e comparação com outros estudos, embora seja formado por mamografias em filme posteriormente digitalizadas e não represente, sozinho, equipamentos ou populações atuais (LEE et al., 2017).

A contribuição acadêmica consiste em um fluxo reprodutível de auditoria, divisão por paciente, treinamento, seleção de parâmetros e análise individual das predições. O protótipo é experimental, não foi validado externamente e não autoriza uso clínico.

1.4 Estrutura do Trabalho

Além desta introdução, o trabalho está organizado em oito seções. A Seção 2 apresenta a fundamentação teórica sobre mamografia, processamento de imagens e segmentação com aprendizado profundo. A Seção 3 revisa estudos relacionados e delimita a lacuna investigada. As Seções 4 e 5 descrevem, respectivamente, a metodologia e o desenvolvimento do sistema. A Seção 6 expõe os resultados quantitativos e qualitativos, e a Seção 7 os discute à luz da literatura, das limitações e dos aspectos éticos. Por fim, a Seção 8 apresenta as conclusões e os trabalhos futuros, seguida das referências na Seção 9.

2. Fundamentação Teórica

2.1 Conceitos Fundamentais de Mamografia Digital

A mamografia utiliza raios X de baixa energia e é empregada no rastreamento e na investigação diagnóstica. A projeção bidimensional, a densidade mamária e a qualidade de aquisição podem dificultar a visualização de lesões, o que exige interpretação especializada. Embora imagens clínicas sejam normalmente armazenadas em DICOM, o CBIS-DDSM deriva de filmes digitalizados e foi utilizado neste estudo em uma cópia previamente convertida, acompanhada de anotações (INCA, 2007; LEE et al., 2017; PEREZ; POLETTI, 2024).

Durante a realização do exame, a mama é posicionada sobre uma plataforma de apoio e submetida à compressão. Esse procedimento busca uniformizar a espessura do tecido, reduzir a sobreposição de estruturas, limitar movimentos e utilizar a radiação de maneira adequada, contribuindo para a nitidez da imagem adquirida (INCA, 2007). O feixe de raios X atravessa o tecido mamário e é registrado por um sistema receptor, formando uma representação em diferentes níveis de cinza.

O padrão DICOM, sigla de Digital Imaging and Communications in Medicine, é amplamente adotado para o armazenamento, a transmissão e o gerenciamento de imagens médicas. Além dos dados de imagem, o arquivo pode conter informações sobre a aquisição, o equipamento e o exame. Scolastici, Melo e Tomal (2017) demonstram que esses metadados podem apoiar programas de garantia de qualidade ao permitir a recuperação automática de parâmetros técnicos.

A mama é formada por tecido glandular, adiposo e fibroglandular, além de estruturas de sustentação. A proporção entre esses componentes varia entre as pessoas e ao longo da vida, sendo influenciada por fatores como idade e alterações hormonais. Na mamografia, a quantidade de tecido fibroglandular está relacionada à densidade mamária. Quanto maior a densidade, maior pode ser a dificuldade de distinguir algumas lesões do tecido sobreposto.

As calcificações aparecem como pequenos focos de alta densidade, e sua morfologia e distribuição auxiliam a avaliação radiológica. Outros achados incluem assimetrias e distorções arquitetônicas. A diversidade das apresentações, somada à sobreposição de estruturas, ajuda a explicar por que a análise mamográfica exige qualidade técnica e interpretação especializada.

2.1.1 Regiões de Interesse em Mamografias

Uma ROI concentra a estrutura analisada e reduz a predominância do fundo. Neste experimento, cada recorte foi calculado a partir da caixa delimitadora da máscara verdadeira, com contexto ao redor da massa. Assim, a avaliação mede a delimitação dentro de uma região conhecida e não a capacidade de localizar uma alteração na mamografia completa.

As ROIs podem ser obtidas de diferentes maneiras. Em um sistema completo, podem ser propostas por um detector automático. Em estudos experimentais de segmentação, também podem ser construídas com base em marcações realizadas por especialistas. Neste segundo cenário, a lesão já está localizada antes da segmentação, de modo que o desempenho medido representa a qualidade da delimitação e não a capacidade de encontrar uma alteração desconhecida na mamografia inteira.

2.2 Processamento Digital de Imagens

O pré-processamento de imagens busca reduzir variações que dificultam a análise computacional e tornar as entradas compatíveis com o modelo. Entre as operações usuais estão a normalização de intensidades, o realce de contraste, o recorte de regiões relevantes e o redimensionamento. A seleção dessas técnicas deve preservar bordas e texturas importantes para a segmentação, evitando introduzir artefatos ou alterar indevidamente as anotações de referência.

2.2.1 Melhoria de Contraste e Filtragem

Entre as técnicas tradicionais de redução de ruído estão os filtros de média e mediana e os métodos baseados em transformadas. O realce de contraste pode ser realizado globalmente ou de forma local, como no CLAHE, que limita a amplificação do contraste em pequenas regiões da imagem (ZUIDERVELD, 1994). A escolha exige cautela, pois uma suavização intensa pode remover detalhes das margens da lesão. No redimensionamento, a interpolação também deve considerar a natureza do dado: imagens contínuas admitem estimativas entre pixels, enquanto máscaras categóricas precisam preservar seus rótulos discretos.

2.3 Fundamentos de Visão Computacional

Detecção, classificação e segmentação são tarefas distintas: a primeira localiza regiões, a segunda atribui rótulos e a terceira produz uma saída por pixel. O módulo desenvolvido executa somente segmentação em ROIs previamente definidas, seu desempenho não comprova detecção de massas nem classificação de câncer.

2.4 Aprendizado de Máquina e Deep Learning

Redes convolucionais aprendem filtros que extraem padrões locais e hierárquicos das imagens. O aprendizado por transferência permite iniciar o treinamento com pesos obtidos em outra base e ajustá-los ao novo domínio, estratégia útil quando as anotações médicas são limitadas (LITJENS et al., 2017). Neste trabalho, a EfficientNetB0 foi inicializada com ImageNet e ajustada como encoder.

O aprendizado profundo é uma vertente do aprendizado de máquina baseada em redes neurais com várias camadas de processamento. A profundidade permite construir representações progressivamente mais abstratas. Em análise de imagens, as primeiras camadas podem responder a bordas e texturas, enquanto níveis posteriores combinam essas informações em padrões mais complexos. O crescimento da capacidade computacional e a disponibilidade de conjuntos rotulados contribuíram para a adoção desses modelos em imagens médicas.

O aprendizado por transferência consiste em utilizar parâmetros aprendidos em uma tarefa de origem para inicializar o treinamento em uma nova tarefa. Em visão computacional, essa estratégia permite aproveitar representações aprendidas por redes pré-treinadas em grandes conjuntos de imagens e adaptá-las ao domínio de interesse, sendo especialmente útil em aplicações de imagens médicas, nas quais a disponibilidade de dados anotados pode ser limitada (LITJENS et al., 2017). A adaptação pode ocorrer com parte das camadas congeladas ou com o ajuste de toda a rede. Neste trabalho, a EfficientNetB0 foi utilizada como encoder e inicializada com pesos pré-treinados no ImageNet (TAN; LE, 2019).

2.5 Segmentação de Imagens com Deep Learning

A U-Net combina encoder, decoder e conexões de salto para reconstruir uma máscara mantendo informações espaciais (RONNEBERGER; FISCHER; BROX, 2015). A saída sigmoide estima a probabilidade de cada pixel pertencer à massa. O treinamento combinou entropia cruzada binária e Focal Tversky, com maior peso para falsos negativos, enquanto Dice e IoU mediram a sobreposição.

Modelos supervisionados aprendem essa tarefa a partir de pares compostos por imagens e máscaras de referência. Durante o treinamento, a rede produz um mapa de probabilidades e compara sua saída à anotação verdadeira. A qualidade do resultado depende da arquitetura, da função de perda, da preparação dos dados e da consistência das máscaras utilizadas como referência.

A função de perda quantifica a diferença entre a saída do modelo e a referência durante o treinamento. O valor calculado orienta a atualização dos pesos da rede. Em segmentação binária, a entropia cruzada binária compara a probabilidade prevista e o rótulo verdadeiro em cada pixel. Sua contribuição é importante para a aprendizagem local, mas o tratamento independente dos pixels pode ser insuficiente diante do desequilíbrio entre fundo e lesão.

3. Revisão Bibliográfica

A literatura sobre apoio computacional à mamografia evoluiu de características definidas manualmente para redes profundas. Esta revisão prioriza trabalhos de segmentação de massas e distingue estudos com mamografias completas, ROIs de referência e fluxos que incluem detecção, pois esses cenários possuem dificuldades e métricas diferentes.

3.1 Histórico e Evolução da Detecção Assistida por Computador em Mamografia

Os primeiros sistemas CAD combinavam processamento de imagens, descritores de forma e textura e classificadores estatísticos (SAMPAT et al., 2005). Com as redes convolucionais, a extração de características passou a ser aprendida a partir dos dados, ampliando aplicações em classificação, detecção e segmentação, sem eliminar a necessidade de avaliar cada tarefa separadamente (LITJENS et al., 2017).

Durante as décadas de 1990 e 2000, o aperfeiçoamento das técnicas de aprendizado supervisionado permitiu combinar descritores de forma, textura e intensidade com classificadores como máquinas de vetores de suporte e redes neurais de poucas camadas. A criação de bases públicas, entre elas o DDSM, também favoreceu a realização de experimentos reprodutíveis e a comparação entre diferentes propostas.

3.2 Abordagens Clássicas para Processamento e Segmentação de Mamografias

Métodos clássicos empregaram limiarização, crescimento de região, contornos ativos e Watershed. Embora úteis para separar intensidades, bordas ou regiões conectadas, essas técnicas são sensíveis a baixo contraste, margens irregulares e variações entre imagens. Elas permanecem relevantes em etapas auxiliares, mas motivaram a adoção de modelos capazes de aprender representações mais complexas.

A principal dificuldade está no fato de que as massas podem apresentar baixo contraste em relação ao tecido próximo, limites pouco definidos e grande variação de tamanho e forma. Em mamas densas, a sobreposição do tecido fibroglandular torna essa separação ainda mais complexa. Por isso, um método clássico que funciona em determinada imagem pode exigir novos parâmetros quando aplicado a outro conjunto.

3.2.1 Métodos de Contorno Ativo e Watershed

Os modelos de contorno ativo representam a borda do objeto por uma curva que se desloca de acordo com forças internas e informações extraídas da imagem. Na segmentação de massas, a curva pode ser inicializada ao redor de uma região suspeita e ajustada progressivamente às transições de intensidade. A técnica permite refinar contornos, mas pode ser sensível à inicialização e apresentar dificuldades diante de margens fracas ou formas muito irregulares (SAMPAT et al., 2005).

3.3 Aplicações de Deep Learning na Segmentação de Lesões Mamárias

Na segmentação profunda, pares de imagens e máscaras orientam uma saída com correspondência espacial. A U-Net tornou-se referência por combinar redução de resolução, reconstrução e conexões de salto. Variações recentes incorporam blocos residuais, atenção, multiescala e encoders pré-treinados para preservar bordas e contexto.

3.3.1 Estudos com Arquiteturas U-Net e Suas Variações

A U-Net foi proposta por Ronneberger, Fischer e Brox (2015) para segmentação de imagens biomédicas e tornou-se uma das principais referências da área. Sua estrutura combina um encoder, que reduz a resolução e extrai características, com um decoder, que reconstrói a máscara. As conexões de salto levam informações espaciais das camadas iniciais para as etapas de reconstrução e favorecem a preservação dos limites do objeto.

3.3.2 Redes Baseadas em Atenção, Multiescala e Estruturas em Cascata

Os mecanismos de atenção buscam atribuir pesos diferentes às características extraídas pela rede, aumentando a contribuição das regiões mais relevantes. O processamento multiescala, por sua vez, combina informações locais e globais para representar tanto as bordas quanto o contexto ao redor da massa. Essas estratégias são recorrentes em propostas recentes porque as lesões variam de tamanho e nem sempre apresentam separação nítida do tecido vizinho.

3.3.3 Segmentação em Regiões de Interesse e em Mamografias Completas

Mamografias completas apresentam forte desequilíbrio entre lesão e fundo e podem perder detalhes no redimensionamento. ROIs ampliam proporcionalmente a massa, mas, quando derivadas da máscara verdadeira, já fornecem sua posição. Por isso, resultados não devem ser comparados apenas por Dice ou IoU sem considerar recorte, divisão por paciente, quantidade de imagens e presença de uma etapa de detecção.

O Quadro 1 compara Baccouche et al. (2021), Su et al. (2022) e Manolakis et al. (2025). O primeiro estudo trabalha com ROIs, enquanto os outros incluem detecção e segmentação em mamografias completas. As diferenças de cenário, divisão dos dados e tarefa impedem uma classificação direta dos métodos por Dice ou IoU.

Quadro 1 – Comparação dos estudos de segmentação de massas mamárias

Estudo	Arquitetura	Cenário	Divisão por paciente	Resultados no CBIS-DDSM
Baccouche et al. (2021)	Connected-Res UNets	Segmentação em ROIs	Não; divisão aleatória dos dados	Dice 0,8952; IoU 0,8002
Su et al. (2022)	YOLO-LOGO com mecanismos de atenção	Detecção e segmentação em mamografias completas	Não explicitada no estudo	F1/Dice 0,745; IoU 0,640
Manolakis et al. (2025)	YOLOv5 e Depthwise SegNet	Detecção e segmentação em duas etapas	Não explicitada no estudo	Dice 0,894; IoU 0,810

Fonte: Elaborado pelo autor com base nos estudos comparados (2026).

3.4 Datasets Públicos e Ferramentas para Pesquisa em Imagens Médicas

O CBIS-DDSM reúne mamografias em filme posteriormente digitalizadas, metadados, recortes e anotações de massas e calcificações (LEE et al., 2017). A base facilita pesquisas reprodutíveis, mas diferenças de aquisição, pré-processamento e formação das ROIs limitam comparações e a generalização para mamografia digital de campo total.

Para as massas, a base oferece máscaras que representam a região anotada e possibilitam experimentos de segmentação. Essas informações também podem ser utilizadas para gerar caixas delimitadoras e recortes centrados na lesão. É importante distinguir a ROI fornecida ou derivada da anotação de uma ROI encontrada por um detector, pois somente a segunda inclui o problema de localização automática.

3.5 Lacunas e Oportunidades Identificadas na Literatura

A revisão evidencia duas lacunas principais: a dependência de localização prévia nos estudos com ROIs e a baixa comparabilidade entre protocolos. Modelos leves e fluxos em duas etapas são alternativas promissoras, mas exigem descrição transparente da divisão dos dados, da origem dos recortes e das métricas utilizadas.

Outra questão está na comparação dos resultados. Valores semelhantes de Dice podem ter sido obtidos com quantidades diferentes de imagens, divisões distintas e recortes construídos por procedimentos não equivalentes. A ausência de informações sobre separação por paciente ou sobre a origem das ROIs dificulta a reprodução e pode levar a interpretações inadequadas.

3.5.1 Posicionamento do Presente Trabalho

O presente trabalho posiciona-se na segmentação de ROIs de referência. Utiliza U-Net com encoder EfficientNetB0, separação por paciente e métricas individuais por imagem. Sua contribuição é a avaliação controlada da delimitação, uma evolução futura deverá integrar um detector e validar o sistema em bases externas.

Em relação aos estudos revisados, a proposta utiliza uma U-Net com encoder EfficientNetB0 inicializado com pesos do ImageNet. O experimento também separa os conjuntos por paciente e mantém resultados individuais por ROI, permitindo analisar a distribuição das métricas e os casos de maior ou menor desempenho. Esses elementos serão apresentados nos capítulos de metodologia e resultados.

4. Metodologia

Trata-se de pesquisa aplicada, experimental e predominantemente quantitativa, complementada por inspeção qualitativa. O experimento avalia a segmentação de massas em ROIs construídas a partir das máscaras do CBIS-DDSM, localização na mamografia completa e classificação diagnóstica não fazem parte do escopo.

4.1 Tipo de Pesquisa e Abordagem

Quanto aos procedimentos técnicos, a pesquisa assume caráter experimental, pois envolve o treinamento controlado de um modelo de aprendizado profundo, o monitoramento de seu comportamento durante o processo de aprendizagem e a avaliação quantitativa das máscaras produzidas em dados não utilizados no treinamento. A validação empírica de modelos constitui uma etapa central em trabalhos de análise de imagens médicas baseados em redes neurais convolucionais (LITJENS et al., 2017).

4.2 Coleta e Preparação dos Dados

A etapa de coleta e preparação dos dados exerce influência direta sobre a consistência do treinamento e sobre a interpretação dos resultados. Em imagens médicas, erros de pareamento, diferenças de dimensão entre a imagem e a máscara e a presença de anotações vazias podem introduzir problemas que não são necessariamente identificados durante o treinamento. Por essa razão, antes da construção das regiões de interesse, foi realizada uma auditoria de todos os pares disponíveis.

4.2.1 Seleção e Aquisição do Dataset CBIS-DDSM

A escolha da base se deve à disponibilidade de imagens acompanhadas de anotações de lesões, necessárias ao treinamento supervisionado de modelos de segmentação. Neste estudo foram considerados somente os arquivos relacionados a massas mamárias. A informação de patologia foi empregada para auxiliar a estratificação dos pacientes entre os conjuntos experimentais, mas não foi fornecida como entrada do modelo e não foi utilizada para produzir uma classificação diagnóstica.

4.2.2 Pareamento e Auditoria das Imagens

Ao todo, foram encontrados 1.318 pares com nomes correspondentes. Cada par foi carregado em escala de cinza e submetido a três verificações. A primeira confirmou a leitura dos dois arquivos. A segunda comparou suas dimensões. A terceira verificou a existência de pixels positivos na máscara após a binarização pelo valor de intensidade 127. Foram considerados inválidos os pares com falha de leitura, dimensões diferentes ou máscara vazia.

4.2.3 Divisão do Conjunto de Dados

Inicialmente foi construída uma tabela com um registro por paciente. Quando um paciente possuía mais de uma amostra, a informação de patologia foi consolidada para permitir a estratificação. A divisão foi realizada com semente aleatória 42. Setenta por cento dos pacientes foram destinados ao treinamento. Os trinta por cento restantes foram divididos igualmente entre validação e teste. A estratificação foi utilizada quando havia quantidade suficiente de pacientes em cada categoria.

4.3 Construção e Pré Processamento das Regiões de Interesse

Para cada máscara, foram identificadas as coordenadas mínimas e máximas dos pixels positivos. A partir dessas coordenadas foi obtida a caixa delimitadora da massa. O centro da caixa foi adotado como centro do recorte, e a maior dimensão da lesão, considerando altura e largura, foi utilizada para estabelecer o lado da região quadrada.

Antes do recorte, intensidades não nulas foram limitadas a 1 e 99,5 e distribuídas entre 0 e 255, em seguida aplicou-se CLAHE com limite 2,0 e grade 8 por 8. A EfficientNetB0 recebeu três cópias do canal em escala de cinza.

4.3.1 Aumento de Dados

As transformações incluíram espelhamento horizontal com probabilidade de 50 por cento e transformação com probabilidade de 70 por cento. O ângulo de rotação foi sorteado entre menos 12 e 12 graus e o fator de escala entre 0,92 e 1,08. Também foram aplicadas variações de intensidade com probabilidade de 60 por cento, combinando multiplicação entre 0,88 e 1,12 e deslocamento entre menos 12 e 12 níveis de cinza. As imagens utilizaram interpolação linear nas transformações geométricas, enquanto as máscaras utilizaram o vizinho mais próximo.

4.4 Arquitetura do Modelo de Deep Learning

A EfficientNet foi proposta com uma estratégia de escalonamento conjunto da profundidade, da largura e da resolução das redes convolucionais, buscando melhor relação entre desempenho e custo computacional (TAN; LE, 2019). Neste trabalho, a variante B0 foi utilizada sem sua camada de classificação e inicializada com pesos obtidos no ImageNet. Essa escolha permitiu empregar transferência de aprendizado na extração inicial de características.

O modelo completo apresentou 8.963.380 parâmetros, dos quais 8.919.373 eram treináveis e 44.007 não treináveis. Todos os parâmetros treináveis do encoder e do decoder permaneceram disponíveis para ajuste durante o treinamento.

4.4.1 Função de Perda

No cálculo adotado, o índice de Tversky atribuiu peso 0,35 aos falsos positivos e 0,65 aos falsos negativos, além de uma constante de suavização igual a 1. A perda focal foi calculada elevando o complemento do índice ao expoente 0,75. A função final correspondeu a 30% da entropia cruzada binária e 70% da perda Focal Tversky. A maior ponderação dos falsos negativos foi escolhida para reduzir a perda de pixels pertencentes à lesão.

4.4.2 Parâmetros de Treinamento e Otimização

O treinamento usou AdamW, taxa inicial de 10^{-4}, decaimento de 10^{-5}, lote 4 e até 70 épocas. O checkpoint acompanhou o Hard Dice de validação, a taxa foi reduzida após seis épocas sem melhora e a parada antecipada ocorreu após 16. Sementes foram fixadas em 42 e empregou-se com precisão mista.

4.5 Seleção do Limiar e Avaliação Final

Foram avaliados limiares entre 0,20 e 0,80, com incremento de 0,025. Para cada valor, a máscara binária foi comparada à referência e o Dice foi calculado individualmente por imagem. O limiar com maior Dice médio na validação foi selecionado e mantido sem alterações na avaliação do teste. O procedimento resultou na escolha do valor 0,80.

4.5.1 Métricas de Segmentação

O Dice foi a métrica principal, também foram calculados IoU, precisão, sensibilidade e especificidade. Os resultados incluíram média, desvio padrão, mediana e Dice global. Como todas as ROIs continham massa, a avaliação representa delimitação de lesões conhecidas e não mede rejeição de regiões negativas.

O índice de Jaccard, também denominado *Intersection over Union* (IoU), relaciona a interseção entre as máscaras à sua união. Na fórmula, P representa o conjunto de pixels preditos como massa e G, o conjunto de pixels da anotação de referência:

$$IoU = \frac{|P \cap G|}{|P \cup G|}$$

A precisão representa a proporção de pixels preditos como massa que realmente pertencem à anotação de referência. A sensibilidade indica a proporção de pixels da massa recuperados pelo modelo. A especificidade corresponde à proporção de pixels externos à massa classificados corretamente como fundo.

4.6 Ambiente de Desenvolvimento e Ferramentas

Os arquivos da base e os artefatos do experimento foram mantidos no Google Drive. Para reduzir o tempo de leitura durante o treinamento, o notebook verificava o espaço disponível e, quando possível, copiava as imagens e máscaras para um cache local temporário do ambiente de execução. Os resultados exportados incluíram o manifesto dos pares válidos, a divisão por paciente, o histórico de treinamento, a busca do limiar, as métricas por imagem, o resumo do teste, as máscaras preditas e os gráficos empregados na análise.

5. Desenvolvimento do Sistema

Neste trabalho, a palavra sistema corresponde ao fluxo computacional experimental implementado no notebook. Não foi desenvolvida uma aplicação clínica com interface para uso por radiologistas. A entrada do modelo também não é uma mamografia sem indicação prévia da lesão. As ROIs são construídas com base nas máscaras de referência do CBIS-DDSM, e o módulo aprende a delimitar a massa dentro desses recortes.

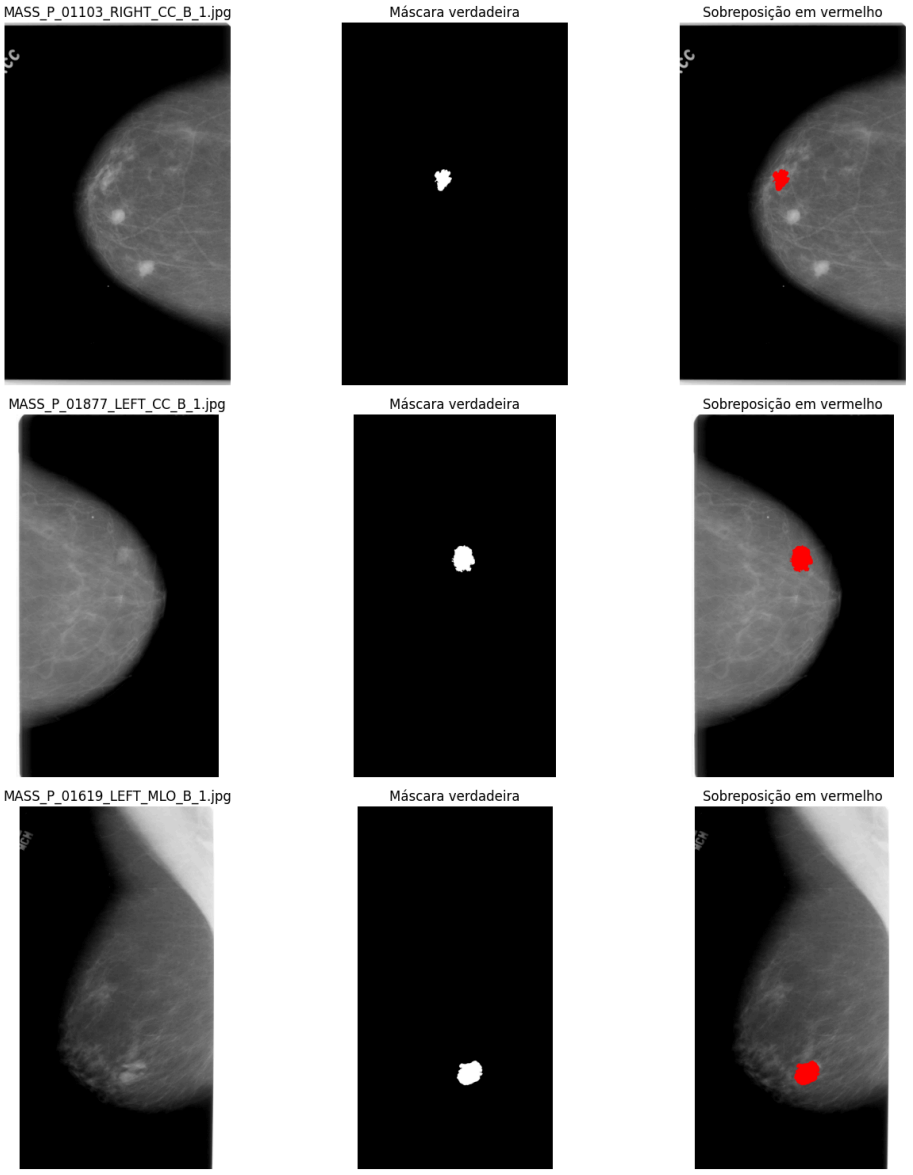
5.1 Módulo de Processamento e Pré-processamento de Imagens

A utilização de recortes permitiu ampliar proporcionalmente a lesão sem reduzir toda a mamografia para 512 por 512 pixels. Ao mesmo tempo, o procedimento manteve tecido ao redor da massa, pois o contexto é necessário para que o modelo diferencie a lesão das estruturas vizinhas.

5.1.1 Conversão DICOM, Carregamento e Normalização das Imagens

O notebook não utilizou os caminhos registrados nos arquivos CSV originais, pois eles se referiam a outro computador. Em seu lugar, as pastas de imagens e máscaras foram indexadas e os arquivos foram pareados pelo nome. Foram encontrados 1.318 pares e três máscaras sem imagem correspondente. Em seguida, cada par foi lido em escala de cinza e submetido a uma auditoria de dimensões e conteúdo. A Figura 1 apresenta exemplos da mamografia completa, da máscara de referência e da sobreposição da anotação.

Figura 1 – Exemplos de mamografia completa, máscara de referência e sobreposição da anotação



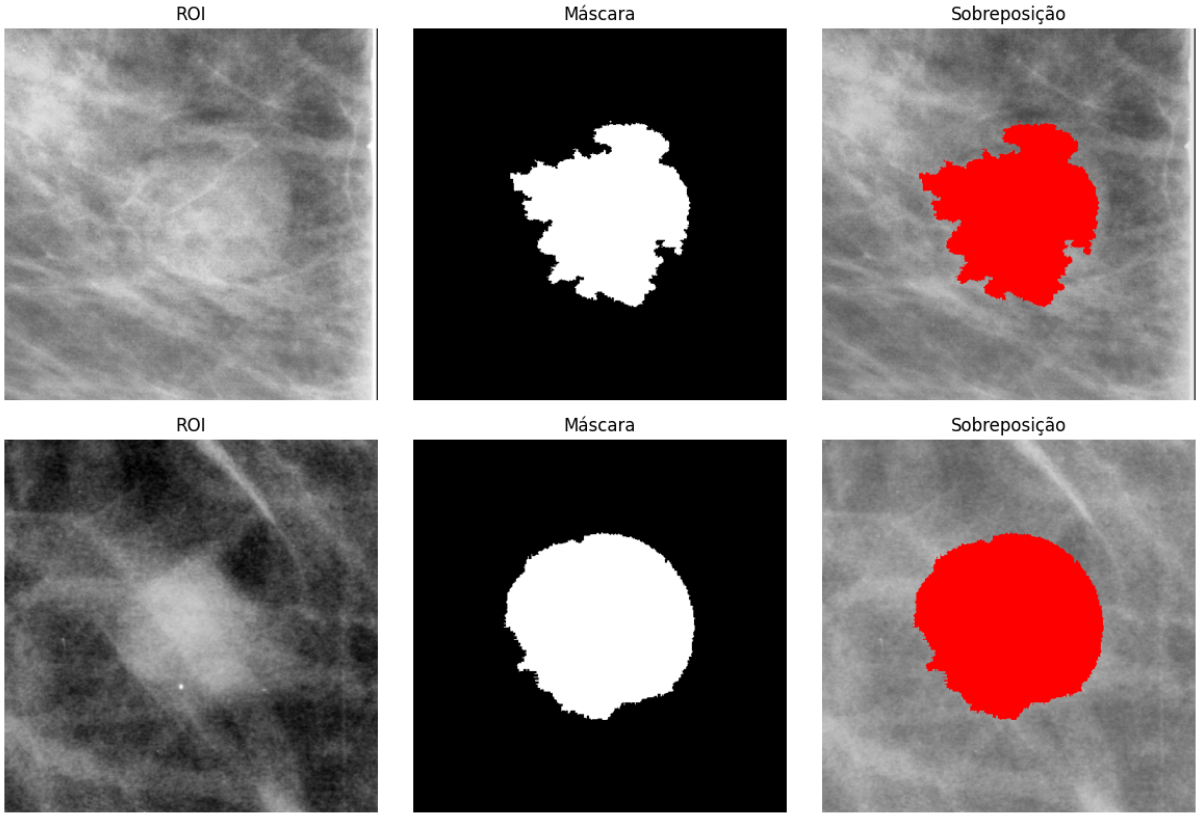
Fonte: Elaborado pelo autor a partir do CBIS-DDSM (2026).

5.1.2 Técnicas de Realce e Construção das Regiões de Interesse

Na sequência, foi aplicado o método CLAHE com limite de contraste igual a 2,0 e grade de 8 por 8 blocos. O CLAHE atua localmente e favorece a visualização de diferenças de intensidade em regiões nas quais o contraste global é reduzido (ZUIDERVELD, 1994). As máscaras não passaram por realce. Elas foram convertidas em imagens binárias por meio do limiar 127.

Durante o treinamento, foram aplicadas transformações aleatórias para ampliar a variedade das amostras. O procedimento incluiu reflexão horizontal, rotações de até 12 graus, variação de escala entre 0,92 e 1,08 e pequenas alterações de intensidade. Cada transformação geométrica foi aplicada da mesma forma à imagem e à máscara. As amostras de validação e teste permaneceram fixas, sem aumento de dados. A Figura 2 exemplifica as ROIs padronizadas, as máscaras binárias e a sobreposição da lesão.

Figura 2 – Exemplos de ROIs padronizadas, máscaras binárias e sobreposição da lesão



Fonte: Elaborado pelo autor a partir do CBIS-DDSM (2026).

5.2 Módulo de Segmentação Automática

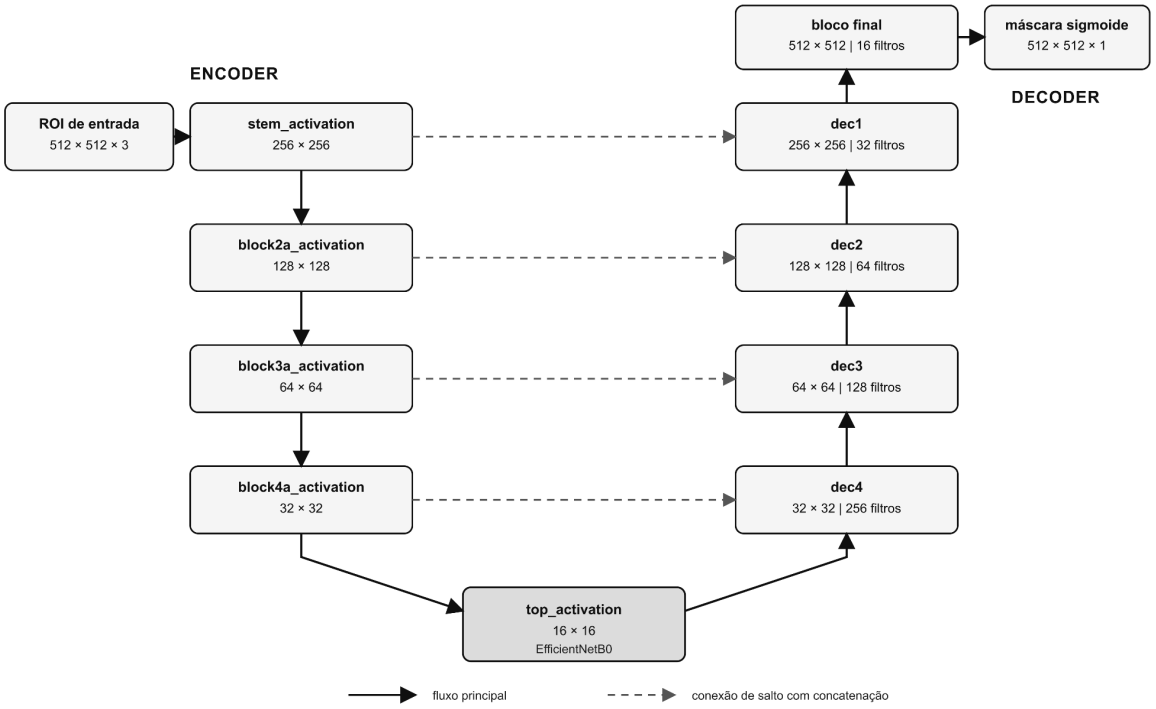
A segmentação seguiu a organização encoder-decoder da U-Net. A EfficientNetB0 extraiu características, enquanto o decoder e as conexões de salto restauraram a resolução e preservaram detalhes espaciais.

5.2.1 Integração e Treinamento do Modelo EfficientNetB0 U-Net

As conexões de salto foram extraídas das camadas stem_activation, block2a_activation, block3a_activation e block4a_activation. O gargalo correspondeu à saída top_activation, com resolução de 16 por 16. No decoder, cada estágio

realizou aumento bilinear da resolução, concatenação com a saída correspondente do encoder e duas convoluções de 3 por 3 pixels. Após cada convolução, foram aplicadas normalização em lote e ativação Swish. A Figura 3 sintetiza a arquitetura EfficientNetB0 U-Net empregada.

Figura 3 – Arquitetura EfficientNetB0 U-Net utilizada na segmentação das ROIs



Fonte: Elaborado pelo autor (2026).

O otimizador escolhido foi o AdamW, com taxa de aprendizado inicial de 0,0001, decaimento de pesos de 0,00001 e limite de norma do gradiente igual a 1,0. O treinamento foi configurado para até 70 épocas, com lotes de quatro amostras e precisão mista. O melhor modelo foi salvo de acordo com o Hard Dice de validação. A taxa de aprendizado era reduzida pela metade após seis épocas sem melhora, e o treinamento era encerrado após 16 épocas sem avanço nessa métrica. Na execução registrada, foram concluídas 61 épocas. O Quadro 2 resume os principais parâmetros do treinamento.

Quadro 2 – Principais parâmetros do treinamento

Parâmetro	Valor utilizado	Finalidade
Tamanho da ROI	512 × 512 pixels	Padronizar a entrada e preservar detalhes da massa
Tamanho do lote	4	Adequar o treinamento à memória da GPU
Épocas máximas	70	Definir o limite do treinamento
Taxa inicial	0,0001	Controlar a atualização dos pesos

Otimizador	AdamW	Otimização com decaimento de pesos
Função de perda	0,30 BCE + 0,70 Focal Tversky	Combinar ajuste por pixel e atenção ao desequilíbrio
Precisão numérica	mixed_float16	Reduzir uso de memória e acelerar operações compatíveis
Semente	42	Aumentar a reprodutibilidade da divisão e das transformações

Fonte: Elaborado pelo autor (2026).

5.2.2 Implementação da Lógica de Inferência e Geração de Máscaras

Após a limiarização, a máscara prevista foi comparada à máscara de referência. O código contabilizou verdadeiros positivos, falsos positivos, falsos negativos e verdadeiros negativos no nível dos pixels. A partir dessas quantidades, foram calculados Dice, IoU, precisão, sensibilidade e especificidade para cada ROI. Também foram registrados o número de pixels da máscara verdadeira, da máscara prevista e da interseção entre elas.

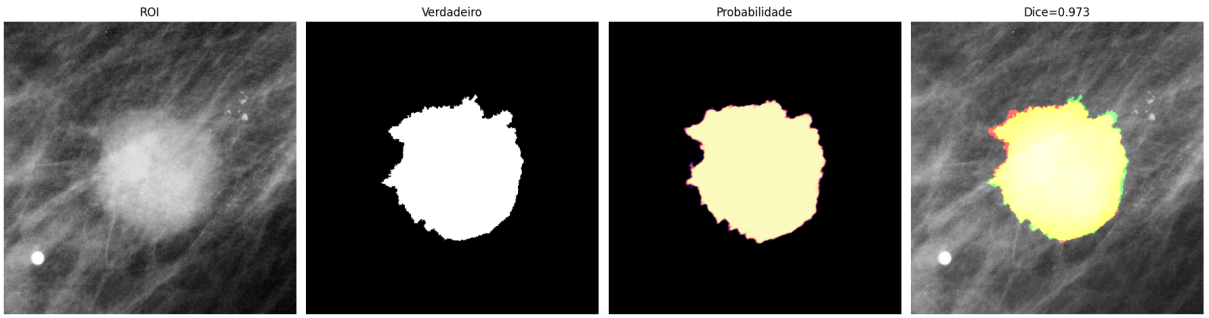
5.3 Módulo de Visualização e Análise de Resultados

As saídas foram estáticas e reprodutíveis, sem interface clínica: figuras em Matplotlib e resultados numéricos em CSV e JSON.

5.3.1 Geração de Mapas de Probabilidade e Sobreposição das Máscaras

Para a inspeção qualitativa, cada exemplo foi organizado em quatro partes: ROI de entrada, máscara de referência, mapa de probabilidade e sobreposição das máscaras. Na sobreposição, a máscara verdadeira e a máscara prevista foram marcadas em canais de cor distintos, permitindo observar regiões coincidentes e diferenças de contorno. A Figura 4 apresenta o formato de visualização das predições.

Figura 4 – Formato de visualização de uma predição gerada pelo módulo



Fonte: Elaborado pelo autor (2026).

5.3.2 Ferramentas de Análise Pós-Segmentação e Relatórios

Os relatórios preservaram identificação da amostra, paciente, incidência, patologia registrada e métricas, além de auditoria, divisão, histórico de treinamento e busca de limiar. A patologia foi usada apenas para estratificação e

descrição, não como entrada ou saída de classificação. O Quadro 3 relaciona os principais artefatos gerados pelo sistema.

Quadro 3 – Principais artefatos gerados pelo sistema

Artefato	Formato	Conteúdo
Auditoria e manifesto	CSV	Dimensões, proporção da máscara e pares válidos
Divisão por paciente	CSV	Identificação dos conjuntos de treino, validação e teste
Histórico do treinamento	CSV	Perda, Dice e taxa de aprendizado por época
Busca do limiar	CSV	Dice de validação para cada limiar avaliado
Métricas por ROI	CSV	Dice, IoU, precisão, sensibilidade e especificidade por imagem
Resumo do teste	JSON	Configuração e métricas agregadas da avaliação final
Pesos do modelo	H5	Melhor checkpoint e pesos ao final do treinamento
Predições e gráficos	PNG e PDF	Mapas de probabilidade, máscaras e figuras de análise

Fonte: Elaborado pelo autor (2026).

Os gráficos produzidos durante a análise dos resultados, incluindo as métricas finais de desempenho, a relação entre o tamanho das massas e o coeficiente Dice e a distribuição dos resultados por classificação patológica, encontram-se disponíveis no repositório do projeto no GitHub (RIGONI, 2026).

5.4 Requisitos de Hardware e Software

A política mixed_float16 foi habilitada para aproveitar a aceleração disponível na GPU e reduzir o consumo de memória. A camada de saída permaneceu em float32 para manter estabilidade no cálculo da máscara e das métricas. Com as ROIs de 512 por 512 pixels, o lote de quatro amostras foi adequado ao ambiente utilizado. O próprio notebook indica a possibilidade de reduzir o lote para duas amostras caso outro ambiente apresente limitação de memória. O Quadro 4 resume o ambiente computacional utilizado.

Quadro 4 – Ambiente computacional utilizado

Componente	Configuração	Uso no projeto
Plataforma	Google Colab Pro	Execução do notebook e acesso ao Google Drive
Processamento	GPU NVIDIA T4	Treinamento e inferência da rede

Framework	TensorFlow 2.20.0 e Keras	Construção, treinamento e carregamento do modelo
Imagens	OpenCV	Leitura, CLAHE, transformações e redimensionamento
Dados	NumPy, pandas e scikit-learn	Manipulação dos dados, divisão e cálculo auxiliar
Visualização	Matplotlib	Geração das figuras e dos gráficos
Persistência	Google Drive e cache local	Armazenamento do conjunto, pesos e relatórios

Fonte: Elaborado pelo autor (2026).

6. Resultados

A avaliação final utilizou 181 ROIs de 99 pacientes, com 88 casos benignos e 93 malignos registrados na base, além de 82 incidências CC e 99 MLO. O checkpoint e o limiar 0,80 foram definidos na validação, sem reajuste no teste.

6.1 Análise Quantitativa dos Resultados da Segmentação

Na validação, o limiar 0,80 apresentou Dice médio de 0,9106. Embora esse tenha sido o maior valor da busca, a variação entre os limiares mais altos foi pequena. Depois dessa escolha, o limiar permaneceu fixo para todas as imagens do teste.

6.1.1 Desempenho nas Métricas de Segmentação

No teste, o Dice macro foi 0,9071 (desvio padrão 0,0594 e mediana 0,9213) e o Dice micro, 0,9125. O IoU médio foi 0,8346, a precisão 0,9027, a sensibilidade 0,9183 e a especificidade 0,9849. A proximidade entre Dice macro e micro indica que o resultado não foi determinado apenas por lesões maiores. O Quadro 5 apresenta o desempenho global no conjunto de testes.

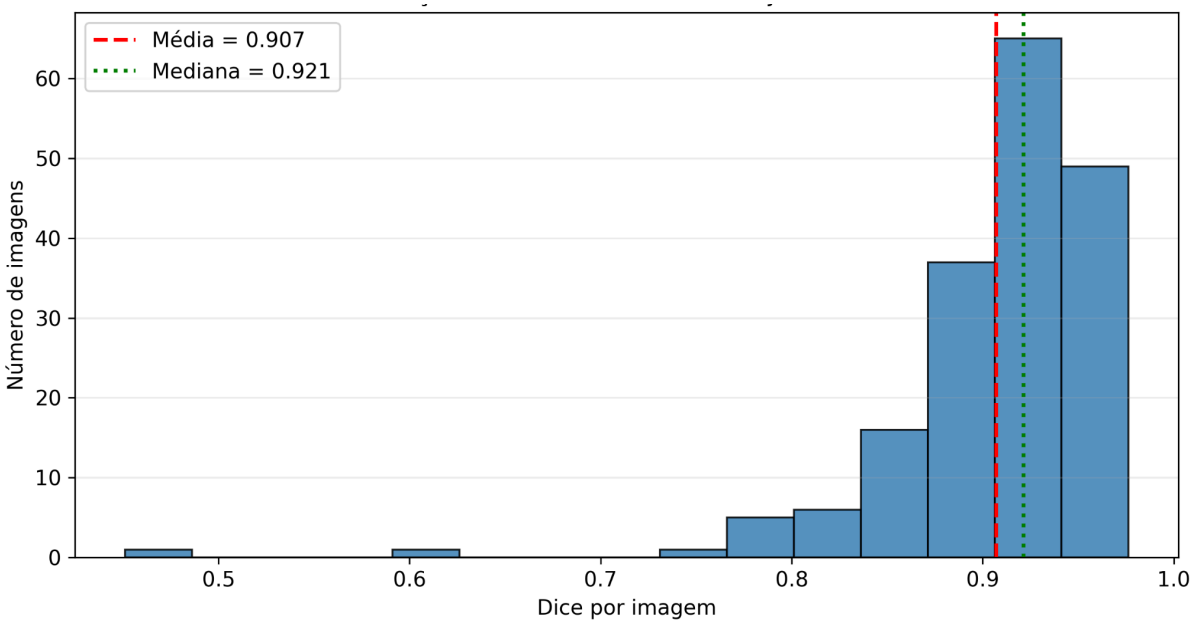
Quadro 5 – Desempenho global no conjunto de teste

Métrica	Valor	Forma de apresentação
Dice macro	0,9071	Média das 181 ROIs
Desvio padrão do Dice	0,0594	Dispersão entre as ROIs
Mediana do Dice	0,9213	Valor central da distribuição
Dice micro	0,9125	Agregação dos pixels de todas as ROIs
IoU	0,8346	Média das 181 ROIs
Precisão	0,9027	Média das 181 ROIs
Sensibilidade	0,9183	Média das 181 ROIs
Especificidade	0,9849	Média das 181 ROIs

Fonte: Dados da pesquisa (2026).

Os valores de Dice variaram de 0,4511 a 0,9763. Das 181 ROIs, 95,6% alcançaram Dice de pelo menos 0,80 e 69,1% atingiram 0,90. A mediana superior à média confirma a concentração em valores altos e a influência de poucos casos de baixo desempenho. A Figura 5 apresenta a distribuição do Dice nas ROIs do teste.

Figura 5 – Distribuição do Dice nas ROIs do conjunto de teste



Fonte: Dados da pesquisa (2026).

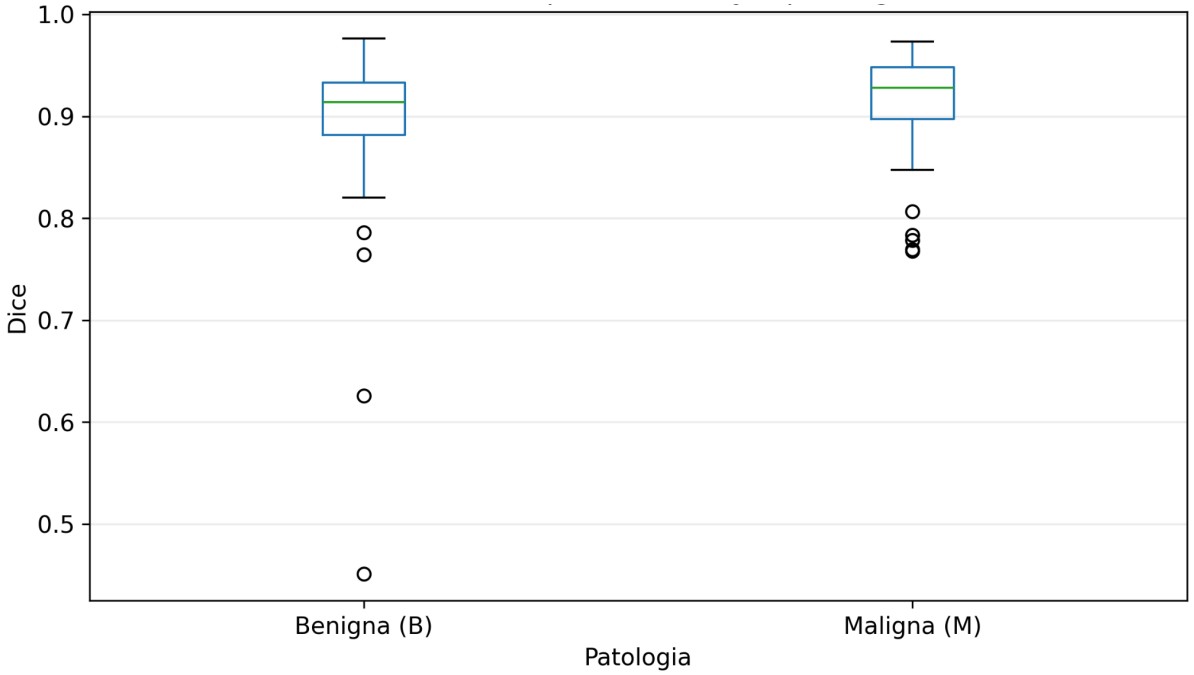
As ROIs malignas apresentaram Dice médio de 0,9167 e as benignas, 0,8970, as incidências CC atingiram 0,9096 e as MLO, 0,9050. As diferenças são apenas descritivas, pois a patologia não foi fornecida ao modelo e não houve teste planejado de classificação. O Quadro 6 resume os resultados descritivos por patologia e incidência, e a Figura 6 apresenta a distribuição do Dice por classificação patológica.

Quadro 6 – Resultados descritivos por patologia e incidência

Grupo	ROIs	Dice médio	Desvio padrão	Mediana	IoU	Sensibilidade
Benigna	88	0,8970	0,0702	0,9140	0,8192	0,9048
Maligna	93	0,9167	0,0452	0,9280	0,8491	0,9311
CC	82	0,9096	0,0535	0,9220	0,8380	0,9221
MLO	99	0,9050	0,0640	0,9183	0,8317	0,9153

Fonte: Dados da pesquisa (2026).

Figura 6 – Distribuição do Dice por classificação patológica registrada no CBIS-DDSM

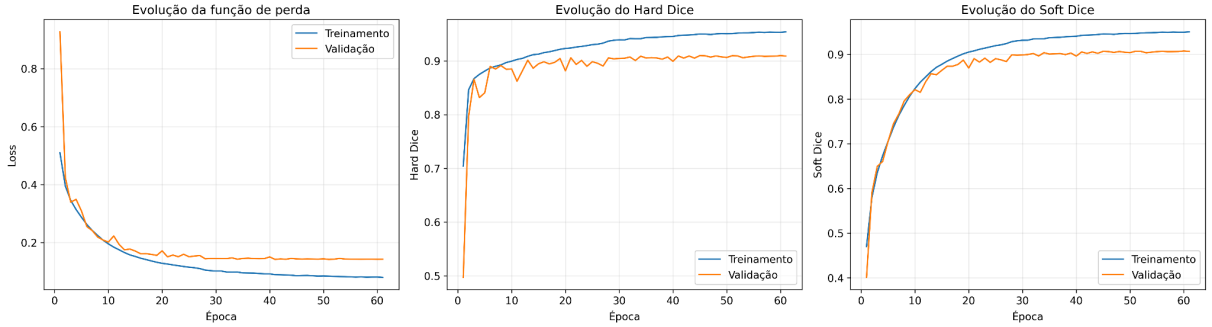


Fonte: Dados da pesquisa (2026).

6.1.2 Curvas de Treinamento e Validação

O treinamento foi encerrado após 61 épocas. O maior Hard Dice de validação foi de 0,9101, registrado na época 45, e definiu o checkpoint utilizado na avaliação final. A menor perda de validação ocorreu na época 51, com valor de 0,1417, enquanto o maior Soft Dice de validação, de 0,9077, foi alcançado na época 60. Como o critério de salvamento estava associado ao Hard Dice, esses resultados posteriores não substituíram o checkpoint selecionado. A ausência de avanço equivalente na validação reforçou a importância da parada antecipada e da preservação do melhor modelo. A Figura 7 apresenta a evolução da perda, do Hard Dice e do Soft Dice durante o treinamento.

Figura 7 – Evolução da função de perda, do Hard Dice e do Soft Dice



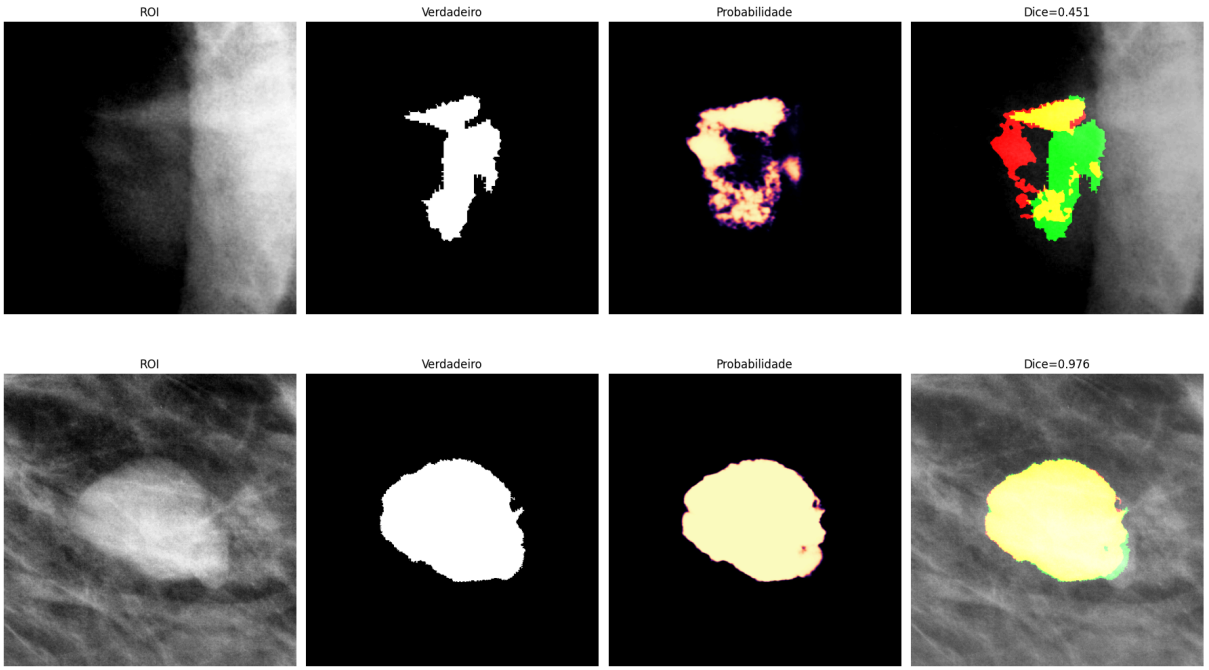
Fonte: Dados da pesquisa (2026).

6.2 Análise Qualitativa da Segmentação

A análise qualitativa comparou ROI, referência, probabilidade e sobreposição. Pixels coincidentes aparecem em amarelo, falsos positivos em vermelho e falsos negativos em verde.

A Figura 8 reúne o caso de menor Dice e o caso de maior Dice no conjunto de teste. Esses exemplos foram selecionados a partir do arquivo de métricas por imagem e representam os extremos observados, sem substituir a avaliação das 181 ROIs.

Figura 8 – Comparação qualitativa entre os extremos de desempenho no conjunto de teste



Fonte: Dados da pesquisa (2026).

O menor caso obteve Dice 0,4511 em uma anotação irregular e descontínua, o maior alcançou 0,9763, com contorno mais contínuo e sobreposição quase completa. Os exemplos confirmam o bom desempenho predominante e a necessidade de analisar falhas individuais.

7. Discussão

Os resultados confirmam a capacidade de delimitar massas em ROIs de referência, mas não medem localização na mamografia completa. A discussão considera desempenho, robustez do protocolo, limitações e condições éticas e regulatórias para uma eventual evolução clínica.

7.1 Interpretação dos Resultados Obtidos

A sensibilidade média de 0,9183 ficou acima da precisão de 0,9027. Em conjunto com a área média prevista, de aproximadamente 36.826 pixels, e a área média da máscara de referência, de aproximadamente 36.345 pixels, esse resultado mostra uma leve tendência de a predição ocupar uma área maior. A diferença média foi de cerca de 1,3 por cento. Ainda assim, o equilíbrio entre precisão e sensibilidade permaneceu próximo, sem predomínio acentuado de perda da lesão ou expansão da máscara.

A distribuição concentrou-se em valores altos, mas poucos casos irregulares reduziram a média. O melhor checkpoint ocorreu na época 45, antes do fim do treinamento, mostrando a utilidade da parada antecipada. Diferenças por

patologia e incidência permaneceram pequenas ou descritivas e não demonstram capacidade diagnóstica.

Nos exemplos qualitativos de menor desempenho, a anotação apresentou formato irregular e regiões descontínuas próximas a tecido de maior intensidade. O modelo recuperou parte da área verdadeira e incluiu pixels externos. Já no caso de maior Dice, o contorno era mais contínuo e a predição acompanhou quase toda a borda de referência. A diferença entre esses casos mostra que o valor médio resume adequadamente o comportamento geral, mas não elimina a necessidade de examinar erros individuais.

Os resultados foram semelhantes entre as incidências, com Dice médio de 0,9096 para CC e 0,9050 para MLO. A pequena diferença observada sugere estabilidade entre as duas projeções dentro da amostra analisada. Essa interpretação não deve ser estendida a outros equipamentos, serviços ou populações sem uma validação externa.

Baccouche et al. (2021) avaliaram modelos da família U-Net no CBIS-DDSM e reportaram Dice de 85,01% e IoU de 73,95% para o Connected-ResUNet. Neste trabalho, os valores foram 0,9071 para Dice e 0,8346 para IoU. Ambos os estudos usam o CBIS-DDSM e métricas de sobreposição entre máscaras, o que permite uma referência contextual. Ainda assim, os resultados diferem em preparação dos dados, divisão das amostras e protocolo de avaliação; portanto, a diferença numérica não demonstra, por si só, superioridade de um modelo.

Su et al. (2022) e Manolakis et al. (2025) propuseram fluxos em duas etapas, combinando a detecção da massa na mamografia com sua segmentação. Su et al. reportaram F1 de 74,5% e IoU de 64,0% no CBIS-DDSM; Manolakis et al. reportaram Dice de 89,4% e IoU de 81,0%. Embora esses trabalhos também avaliem a segmentação de massas no CBIS-DDSM, eles precisam localizar a lesão antes de segmentá-la. Neste estudo, a ROI é construída com a máscara verdadeira, de modo que a avaliação se concentra na delimitação de uma lesão já localizada. Assim, os resultados ajudam a contextualizar o desempenho, mas não constituem uma comparação direta entre métodos.

7.2 Pontos Fortes e Contribuições

Os pontos fortes incluem definição precisa do problema, divisão por paciente, seleção de checkpoint e limiar somente na validação, auditoria dos pares e construção determinística das ROIs. Esses controles reduzem vazamento de informação e inconsistências entre imagens e máscaras.

A divisão do conjunto por paciente também fortalece o experimento. Imagens CC, MLO ou de lados diferentes do mesmo paciente permaneceram no mesmo subconjunto. Esse procedimento reduz o risco de o modelo encontrar no teste características muito semelhantes às observadas no treinamento e torna a estimativa de generalização mais confiável dentro da própria base.

O processo de auditoria identificou pares com dimensões incompatíveis e evitou o treinamento com imagens e máscaras desalinhadas. A construção determinística das ROIs, o redimensionamento específico para imagens e máscaras e a aplicação conjunta das transformações geométricas reduziram as fontes de inconsistência entre entrada e referência.

A contribuição principal é um fluxo reprodutível para segmentação de massas previamente localizadas, com métricas por ROI e registro de dados, pesos, predições e histórico. A arquitetura não é inédita, mas foi implementada e avaliada de forma coerente com o escopo.

7.3 Limitações do Estudo e Desafios Encontrados

A principal limitação é a dependência da máscara de referência para a construção das ROIs. Como todas as amostras continham massas previamente localizadas, o estudo não permite avaliar falsos alarmes em exames normais nem erros decorrentes de uma etapa de detecção. Além disso, foi utilizada apenas uma base composta por mamografias em filme posteriormente digitalizadas, sem validação externa ou dados provenientes da população brasileira.

A conversão das imagens de DICOM para PNG ocorreu fora do notebook, o que limita a rastreabilidade dessa etapa. Durante a auditoria, também foram excluídos 65 pares porque as imagens e suas respectivas máscaras apresentavam dimensões incompatíveis. Essa decisão evitou o uso de anotações possivelmente desalinhadas, mas reduziu o conjunto de dados e pode ter alterado sua composição caso as incompatibilidades estejam associadas a determinados tipos de imagem ou lesão. A origem desses casos deverá ser investigada antes de uma nova avaliação.

Por fim, o limiar ótimo coincidiu com o limite superior do intervalo pesquisado, de 0,80, indicando a necessidade de uma busca futura mais ampla. Também não foram estimados intervalos de confiança ajustados por paciente nem avaliados o tempo de inferência, o consumo de memória, a calibração, a incerteza ou a estabilidade do modelo diante de variações de ruído e contraste.

7.4 Implicações Clínicas e Impacto Potencial na Rotina Radiológica

Em um fluxo futuro, um detector poderia localizar candidatos e o módulo produzir contornos para revisão do radiologista. O resultado atual não demonstra redução de tempo, aumento de detecção ou validade de medidas físicas, essas hipóteses exigem mamografias completas, exames negativos, dados externos e estudos com profissionais.

Uma máscara consistente pode auxiliar atividades como documentação do achado, análise de forma e acompanhamento de alterações. Entretanto, as ROIs foram redimensionadas para 512 por 512 pixels e o fluxo atual não preserva uma relação direta com medidas físicas em milímetros. Portanto, o sistema ainda não deve ser utilizado para fornecer medidas clínicas ou acompanhar crescimento sem recuperar corretamente a geometria e os metadados do exame original.

Dentro do escopo atual, o impacto potencial está na demonstração de que a delimitação automática em regiões previamente localizadas é viável. A relação com a detecção precoce é indireta: a máscara pode compor uma etapa de um sistema maior, mas o protótipo isolado não localiza a lesão nem determina benignidade ou malignidade.

7.5 Aspectos Éticos e Regulatórios na Aplicação de IA em Saúde

Dados de saúde exigem finalidade, controle de acesso, retenção adequada e proteção contra reidentificação, conforme a LGPD (BRASIL, 2018). Uma única base também pode ocultar diferenças de desempenho entre populações,

equipamentos e densidades mamárias, tornando representatividade e transparência requisitos éticos.

A representatividade dos dados também é uma questão ética. Um modelo treinado em uma única base pode apresentar desempenho diferente em populações não representadas. No presente estudo, não foram avaliados grupos segundo idade, raça, densidade mamária, equipamento ou instituição. Uma aplicação clínica sem essa análise poderia distribuir erros de forma desigual e ampliar diferenças já existentes no acesso ao diagnóstico.

A Resolução CFM nº 2.454/2026 preserva a autonomia e responsabilidade médicas e exige validação, governança e monitoramento (CFM, 2026). A RDC Anvisa nº 657/2022 estabelece requisitos para software como dispositivo médico (ANVISA, 2022). O protótipo é acadêmico, sem autorização assistencial, e qualquer evolução deve manter supervisão humana.

Uma futura versão clínica precisaria manter registros de versão, dados de treinamento, desempenho por subgrupo, alterações do modelo e eventos adversos. Também seriam necessários mecanismos para suspender o uso diante de queda de desempenho, proteger o sistema contra acesso indevido e garantir que a equipe compreenda quando a saída não é confiável.

8. Conclusões

O trabalho alcançou o objetivo de desenvolver e avaliar um módulo de segmentação de massas em ROIs do CBIS-DDSM. O recorte preservou detalhes, mas dependeu das anotações e restringiu o alcance à delimitação de lesões já localizadas. Portanto, as conclusões não abrangem detecção, diagnóstico ou uso clínico. Os resultados mostraram boa concordância com as máscaras de referência na maior parte das imagens, mas permanecem restritos ao conjunto de teste utilizado.

8.1 Resumo dos Objetivos Alcançados e Contribuições

O fluxo integrou auditoria, divisão por paciente, pré-processamento, U-Net com encoder EfficientNetB0, seleção de checkpoint e limiar na validação e avaliação quantitativa e visual. O registro de métricas e predições por ROI permitiu identificar tanto o desempenho geral quanto casos de falha. O fluxo também preservou resultados individuais e comparações visuais entre entrada, referência e predição, facilitando a identificação de casos de bom desempenho e de divergências de contorno.

8.2 Síntese dos Principais Resultados e Aprendizados

Nas 181 ROIs de 99 pacientes, o modelo obteve Dice 0,9071, IoU 0,8346, precisão 0,9027 e sensibilidade 0,9183. Ao todo, 95,6% das ROIs alcançaram Dice ≥ 0,80. A concentração em valores altos sustenta a viabilidade da segmentação no cenário estudado, enquanto os poucos resultados baixos reforçam a necessidade de inspeção individual.

O melhor checkpoint ocorreu na época 45, e o limiar 0,80 foi escolhido fora do teste. A separação por paciente e a exclusão de pares desalinhados aumentaram a confiabilidade, mas a conversão DICOM-PNG e os casos incompatíveis precisam ser mais bem documentados e investigados.

8.3 Trabalhos Futuros

O próximo passo consiste em processar mamografias completas por meio de um fluxo composto por duas etapas: detecção de regiões candidatas e segmentação. A avaliação deverá incluir exames normais, falsos candidatos, lesões pequenas e múltiplos achados, permitindo medir conjuntamente os erros de localização e de delimitação dos contornos.

Trabalhos futuros também deverão integrar o processamento de arquivos DICOM ao pipeline, preservando a geometria e os metadados dos exames, além de ampliar a busca pelo limiar de binarização e avaliar incerteza, tempo de inferência e consumo de memória. Será necessária uma validação externa em mamografias digitais de campo total provenientes de diferentes equipamentos, instituições e populações, incluindo, sempre que possível, serviços brasileiros e pacientes com diferentes densidades mamárias e características clínicas. Essa avaliação permitirá verificar se o desempenho observado no CBIS-DDSM se mantém diante de mudanças na população e nas condições de aquisição.

Por fim, uma futura versão exigirá estudos com radiologistas, mecanismos de proteção de dados, regularização pelos órgãos competentes e supervisão profissional.

Referências

ABRAHAM, Nabila; KHAN, Naimul Mefraz. A novel Focal Tversky loss function with improved Attention U-Net for lesion segmentation. In: IEEE INTERNATIONAL SYMPOSIUM ON BIOMEDICAL IMAGING, 16., 2019, Venice. Proceedings [...]. Piscataway: IEEE, 2019. p. 683–687. DOI: 10.1109/ISBI.2019.8759329.

AGÊNCIA NACIONAL DE VIGILÂNCIA SANITÁRIA (ANVISA). Resolução da Diretoria Colegiada RDC nº 657, de 24 de março de 2022. Dispõe sobre a regularização de software como dispositivo médico (Software as a Medical Device, SaMD). Diário Oficial da União: seção 1, Brasília, DF, n. 61, p. 330, 30 mar. 2022. Disponível em: https://pesquisa.in.gov.br/imprensa/servlet/INPDFViewer?data=30/03/2022&jornal=515&pagina=330. Acesso em: 27 ago. 2026.

BACCOUCHE, Asma; GARCIA-ZAPIRAIN, Begonya; CASTILLO OLEA, Cristian; ELMAGHRABY, Adel S. Connected-UNets: a deep learning architecture for breast mass segmentation. npj Breast Cancer, v. 7, art. 151, 2021. DOI: 10.1038/s41523-021-00358-x.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais. Brasília, DF: Presidência da República, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709compilado.htm. Acesso em: 27 ago. 2026.

CONSELHO FEDERAL DE MEDICINA (CFM). Resolução CFM nº 2.454, de 11 de fevereiro de 2026. Normatiza o uso da inteligência artificial na medicina. Diário Oficial da União: seção 1, Brasília, DF, n. 39, p. 158, 27 fev. 2026. Disponível em: https://sistemas.cfm.org.br/normas/visualizar/resolucoes/BR/2026/2454. Acesso em: 27 ago. 2026.

INSTITUTO NACIONAL DE CÂNCER. Estimativa 2023: incidência de câncer no Brasil. Rio de Janeiro: INCA, 2022. Disponível em: https://www.inca.gov.br/sites/ufu.sti.inca.local/files/media/document/estimativa-2023.pdf. Acesso em: 27 ago. 2026.

INSTITUTO NACIONAL DE CÂNCER. Mamografia: da prática ao controle. Rio de Janeiro: INCA, 2007. Disponível em: https://www.inca.gov.br/publicacoes/livros/mamografia-da-pratica-ao-controle. Acesso em: 26 ago. 2026.

LEE, Rebecca Sawyer et al. A curated mammography data set for use in computer-aided detection and diagnosis research. Scientific Data, v. 4, art. 170177, 2017. DOI: 10.1038/sdata.2017.177.

LITJENS, Geert et al. A survey on deep learning in medical image analysis. Medical Image Analysis, v. 42, p. 60–88, 2017. DOI: 10.1016/j.media.2017.07.005.

MANOLAKIS, Dimitris et al. A two-stage lightweight deep learning framework for mass detection and segmentation in mammograms using YOLOv5 and Depthwise SegNet. Journal of Imaging Informatics in Medicine, v. 38, p. 3852–3867, 2025. DOI: 10.1007/s10278-025-01471-0.

PEREZ, Alessandra Maia Marques Martinez; POLETTI, Martin Eduardo. Caracterização de sistemas de mamografia digital no domínio da frequência para diferentes condições de exposição. Revista Brasileira de Física Médica, v. 18, 2024. Disponível em: https://rbfm.org.br/rbfm/article/view/785. Acesso em: 26 ago. 2026.

RIGONI, João Pedro Guinati. TCC – Segmentação de massas em regiões de interesse de mamografias. GitHub, 2026. Disponível em: https://github.com/joaopedrogr/TCC-SEGMENTACAO-DE-MASSAS-EM-REGIOES-DE-INTERESSE-DE-MAMOGRAFIAS. Acesso em: 23 out. 2026.

RONNEBERGER, Olaf; FISCHER, Philipp; BROX, Thomas. U-Net: convolutional networks for biomedical image segmentation. In: INTERNATIONAL CONFERENCE ON MEDICAL IMAGE COMPUTING AND COMPUTER-ASSISTED INTERVENTION, 18., 2015, Munich. Lecture Notes in Computer Science. Cham: Springer, 2015. v. 9351, p. 234–241. DOI: 10.1007/978-3-319-24574-4_28.

SAMPAT, Mehul P. et al. Computer-aided detection and diagnosis in mammography. In: BOVIK, Al C. (ed.). Handbook of Image and Video Processing. 2. ed. Burlington: Academic Press, 2005. p. 1195–1217.

SCOLASTICI, Éric Francisco; MELO, Camila Souza; TOMAL, Alessandra. Metodologia de coleta semi-automática de dados em mamografia digital e análises críticas para um programa de garantia de qualidade. Revista Brasileira de Física Médica, v. 10, n. 1, p. 27–30, 2017. DOI: 10.29384/rbfm.2016.v10.n1.p27-30.

SU, Yongye; LIU, Qian; XIE, Wentao; HU, Pingzhao. YOLO-LOGO: a transformer-based YOLO segmentation model for breast mass detection and segmentation in digital mammograms. Computer Methods and Programs in Biomedicine, v. 221, art. 106903, 2022. DOI: 10.1016/j.cmpb.2022.106903.

TAN, Mingxing; LE, Quoc V. EfficientNet: rethinking model scaling for convolutional neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 36., 2019, Long Beach. Proceedings of Machine Learning Research, v. 97, p. 6105–6114, 2019. Disponível em: https://proceedings.mlr.press/v97/tan19a.html. Acesso em: 26 ago. 2026.

THE CANCER IMAGING ARCHIVE. CBIS-DDSM: Curated Breast Imaging Subset of DDSM. 2017. Disponível em: https://www.cancerimagingarchive.net/collection/cbis-ddsm/. Acesso em: 26 ago. 2026.

ZUIDERVELD, Karel. Contrast limited adaptive histogram equalization. In: HECKBERT, Paul S. (ed.). Graphics Gems IV. San Diego: Academic Press Professional, 1994. p. 474–485. DOI: 10.1016/B978-0-12-336156-1.50061-6.